


PROCESAMIENTO DE IMÁGENES BIOMÉDICAS INSTITUTO TECNOLÓGICO DE BUENOS AIRES

Trabajo Práctico Final



Profesores: Roberto Sebastián TOMÁS
Francisco TASSARA
Aylin VAZQUEZ CHENLO
Julian BERGMAN

Alumnos/as: Victoria ÁLVAREZ
Josefina BRAU
Felipe OLIVERA RIAL
Tomas LEW

Presentación	
Desarrollo	
Conclusiones	
Nota Final	
Firma y Fecha	

Índice

1. Resumen	1
2. Introducción	1
2.1. Contextualización	1
2.2. Justificación	2
3. Objetivos	2
4. Desarrollo	3
4.1. Base de datos	3
4.2. Pre-procesamiento y Mejoramiento	3
4.3. Identificación de Atributos Característicos	4
4.4. Segmentación y Extracción de Características	5
4.5. Diagnóstico Final	6
5. Resultados	6
5.1. Rendimiento del clasificador	6
5.2. Funcionalidad de la interfaz	7
6. Conclusión	8
7. Referencias	9
8. Anexo	10

1. Resumen

En el siguiente trabajo se desarrolla una interfaz gráfica que, mediante la implementación de tanto técnicas de procesamiento de imágenes aprendidas durante la cursada, como otras adquiridas de la bibliografía consultada, permite obtener un diagnóstico respecto a la condición retinal (normal o patológica) de lo observado en una tomografía de coherencia óptica, cargada por el usuario.

2. Introducción

2.1. Contextualización

La Tomografía de Coherencia Óptica (OCT, por sus siglas en inglés) es una técnica de imagen no invasiva y potente que utiliza interferometría de baja coherencia para obtener imágenes multidimensionales de alta resolución del tejido biológico de la retina. La OCT proporciona una imagen seccional en vivo de las capas de la retina, permitiendo detectar la pérdida de las características normales de la misma, como el grosor, la suavidad y la organización, debido a diversas condiciones patológicas, incluyendo la neovascularización coroidea, la degeneración macular relacionada con la edad (AMD) y los eventos vasculares retinianos [1].




Figura 1: Imagen obtenida mediante OCT [2].

En las imágenes obtenidas a partir de esta técnica, se puede visualizar el humor vítreo, la retina neurosensorial, desde la membrana limitante interna (MLI) hasta los fotorreceptores (FR), el epitelio pigmentario de la retina (EPR), la coriocapilar (CC) y la membrana de Bruch, la coroides, la esclera y el nervio óptico.

La neovascularización coroidea (CNV) es una característica distintiva de la etapa avanzada de la degeneración macular relacionada con la edad (AMD) y se caracteriza por el crecimiento de vasos sanguíneos anormales desde la coroides a través de la membrana de Bruch y bajo el epitelio pigmentario de la retina (tipo 1), con posible extensión hacia el espacio subretiniano (tipo 2). Actualmente, la clasificación clínica de la AMD neovascular se basa en la angiografía con fluoresceína (FA), la angiografía con indocianina (ICGA) y las imágenes estructurales obtenidas mediante tomografía de coherencia óptica (OCT) [1].

El edema macular diabético (DME) se caracteriza por el engrosamiento de la retina y la acumulación de fluido intrarretiniano (IRF) debido a la permeabilidad y filtración vascular anormal en la retinopatía diabética (DR) y la diabetes mellitus. Es una de las principales causas de ceguera entre

los adultos en edad laboral. La detección y el tratamiento oportunos del DME son fundamentales para estabilizar la visión. Las pruebas clínicas mediante OCT tridimensional se reconocen cada vez más como el estándar de referencia para la detección del DME. Los ensayos clínicos que investigan las terapias para el DME han utilizado el grosor central de la retina derivado de la OCT como criterio de inclusión y punto final clínico. Otro marcador importante de la actividad del DME en la OCT es la presencia de IRF, que permite evaluar la respuesta al tratamiento [3].




Figura 2: De izquierda a derecha: CNV con membrana neovascular (punteros blancos) y fluido subretiniano asociado (flechas), DME con engrosamiento de retina y acumulación de IRF (flechas), y retina normal.

2.2. Justificación

La OCT se ha convertido en una de las técnicas de imagen médica más comunes a nivel mundial, con aproximadamente 30 millones de exploraciones realizadas cada año [4]. Como se mencionó previamente, es fundamental en el diagnóstico y tratamiento de enfermedades oculares graves, como la AMD y el DME. En Estados Unidos, casi 10 millones de personas padecen AMD, y anualmente más de 200000 desarrollan CNV. Además, cerca de 750000 individuos mayores de 40 años sufren de DME. Se espera que la prevalencia de estas enfermedades aumente debido al envejecimiento de la población [4], motivo por el cual es de interés optimizar su diagnóstico.

La introducción y el uso generalizado de medicamentos anti-factor de crecimiento endotelial vascular (anti-VEGF) han revolucionado el tratamiento de enfermedades retinianas exudativas, permitiendo a los pacientes conservar una visión útil y mejorar su calidad de vida [4]. La OCT es crucial para guiar la administración de la terapia anti-VEGF, ya que proporciona una representación transversal clara de la patología retiniana, lo cual es imposible de lograr mediante el examen clínico humano o la fotografía de fondo de ojo en color.

En este contexto, desarrollamos un algoritmo de clasificación para retinas con tres condiciones: DME, CNV y retinas normales. El objetivo es mejorar la precisión y rapidez en el diagnóstico, permitiendo una mejor planificación del tratamiento.

3. Objetivos

Se propone una interfaz de fácil interpretación que le permite al usuario subir la imagen por clasificar y obtener el diagnóstico de la misma, junto a los parámetros extraídos de la imagen, determinantes en su clasificación. Además, se diseña de forma tal que se puedan visualizar las imágenes correspondientes a las distintas instancias de la clasificación, siendo estas la imagen con los vasos y regiones de fluido intrarretiniano etiquetados, y la imagen con la segmentación del epitelio pigmentario retinal (EPR), y su respectiva regresión parabólica.

4. Desarrollo

4.1. Base de datos

La base de datos utilizada en este proyecto está organizada en tres carpetas principales (entrenamiento, prueba y validación), cada una de las cuales contiene subcarpetas para cada categoría de imagen (NORMAL, CNV y DME), además de una subcarpeta adicional correspondiente a la condición de DRUSEN, que no se aborda en este proyecto. En total, la base de datos incluye 84,495 imágenes de OCT en formato JPEG [6], etiquetadas como (enfermedad)-(ID aleatorio del paciente)-(número de imagen por este paciente).

Procedencia de las Imágenes. Las imágenes de OCT (Spectralis OCT, Heidelberg Engineering, Germany) fueron seleccionadas de cohortes retrospectivas de pacientes adultos de diversas instituciones entre el 1 de julio de 2013 y el 1 de marzo de 2017.[5]

Proceso de Verificación y Corrección de Etiquetas. Antes del entrenamiento, cada imagen pasó por un sistema de clasificación en múltiples niveles, consistiendo en varias capas de evaluadores entrenados (estudiantes de pregrado y medicina que aprobaron un curso de interpretación de OCT, oftalmólogos y especialistas retinianos, con más de 20 años de experiencia clínica) para la verificación y corrección de las etiquetas de las imágenes, asegurando un etiquetado correcto [5].

4.2. Pre-procesamiento y Mejoramiento

Como primer paso, se optó por la vía tradicional y se intentó filtrar el ruido presente en la imagen mediante la aplicación de un filtro Gaussiano dado que, al analizar el histograma de las mismas, presentan la distribución acampanada característica del ruido Gaussiano. No obstante, los resultados obtenidos a partir de este filtrado no fueron buenos, ya que la imagen se disfundaba pero el ruido permanecía (en especial en el fondo) (Figura 3).




Figura 3: Imagen filtrada con un filtro Gaussiano.

Es por ello que se optó por una vía alternativa para reducir al máximo el ruido presente en el fondo, que interfería fuertemente con el posterior análisis. El nuevo enfoque consistió en segmentar la retina completa para aislarla del fondo, siguiendo los pasos mencionados a continuación:

Extracción de zonas blancas. A partir del análisis de las imágenes de la base de datos fue posible notar que la retina en sí no contiene píxeles de valores de gris mayores a 250. Además, se reconoció que muchas imágenes tenían bordes blancos en el fondo que alteraban el procesamiento posterior. En base a esto, se eliminan las zonas muy blancas de la imagen que superan un umbral especificado (`white_thresh`), convirtiéndolas a negro.

Filtrado Gaussiano. Se aplica un filtro Gaussiano para suavizar la imagen y reducir el ruido inicial. El filtro utiliza un kernel de tamaño 5x5.

Eliminación de ruido con NL-Means. Se aplica la técnica de eliminación de ruido Non-Local Means (NL-Means) utilizando un valor de sigma estimado, de acuerdo a lo recomendado en la bibliografía consultada [5]. Esta técnica reduce el ruido preservando las estructuras importantes de la imagen.

Aislamiento de la retina. Se etiquetaron todas las regiones de valor de pixel 255 mediante un algoritmo propio de etiquetado, utilizando el método de Otsu para la binarización inicial. Luego, se identificó la región etiquetada de mayor tamaño y se creó una nueva imagen binaria cuyo fondo fuera negro, y donde la región seleccionada tuviese valor de pixel de 255. Como se puede observar en la Figura 8 del Anexo, en esta imagen binaria la retina no es un bloque blanco compacto, sino que presenta espacios negros. Por esto, se creó la función "Fill," que rellena los espacios vacíos. Posteriormente, se cambió el valor de estos píxeles blancos a 1 y se realizó el producto entre la imagen resultante y la original, creando una imagen de fondo limpio.

Recorte de la imagen. Finalmente, se utiliza el método de bounding box para enmarcar la retina de forma tal que la imagen final incluya un fondo negro en menor proporción, y el objeto principal en mayor proporción.

Las distintas instancias descritas se pueden observar en la Figura 8, ubicada en el Anexo. A continuación, se muestran la imagen original y la obtenida al finalizar el mejoramiento:




Figura 4: Inicio (Imagen original - izquierda) y fin (derecha) del proceso de pre-procesamiento y mejoramiento de la imagen.

4.3. Identificación de Atributos Característicos

Una vez mejoradas las imágenes, el próximo paso consistió en la elección de atributos intrínsecos de cada condición, con la idea de poder distinguir características únicas y distintivas de cada conjunto a fin de posteriormente clasificarlas en base a estas.

Analizando la base de datos, fue sencillo destacar el hecho de que los conjuntos de CNV y DME presentan regiones negras en la retina. Estas regiones se deben a la neovascularización en el caso de las retinas con CNV y a la acumulación de fluido intrarretiniano en el caso del edema macular diabético. Por lo tanto, este fue nuestro primer parametro a analizar.

En segundo lugar, una de las principales diferencias entre estas dos condiciones se da en la morfología del epitelio pigmentario retinal (EPR). Dada la neovascularización producida en la coroides,

las retinas que sufren de CNV también sufren una deformación significativa del epitelio. Tanto en el caso de las retinas normales como las que sufren de DME, este epitelio, que en las imágenes se ve como una línea con altos valores de intensidad, posee una forma "parabólica". Cuando crece un nuevo vaso, esta zona se ensancha y se vuelve más irregular. En base a esto, se puede notar que, trazando una curva de mayor ajuste, en el caso de una retina con CNV, el coeficiente de determinación R^2 será menor que en el caso de una retina sana o una retina que sufra de infiltraciones intrarretinianas.

4.4. Segmentación y Extracción de Características

Para la obtención del primer parámetro, se segmentaron las distintas regiones de la retina utilizando el algoritmo K-Means con $K = 3$. Se eligió este valor debido a que permite tener tres tonalidades distintivas: la más oscura, correspondiente al fondo y a los vasos o a las acumulaciones de fluido intrarretinal, la intermedia, correspondiente a la mayor parte de la retina, y la de mayor intensidad, correspondiente a regiones particulares de la retina, entre ellas, el EPR. Una vez segmentada la imagen, se utilizó un algoritmo de etiquetado para hacer un conteo de los objetos con el menor valor de intensidad observado en la imagen. En este caso, en vez de determinar el umbral de la binarización por Otsu, se utilizó $1 + \min(k_means)$ como umbral. De esta forma, tras la binarización, los únicos elementos de intensidad 0 son el fondo u cualquier vaso o acumulación de fluido intrarretinal. Adicionalmente, definimos un umbral de tamaño para eliminar las etiquetas muy pequeñas, que posiblemente representan ruido. Así, se logra etiquetar únicamente las regiones oscuras con un tamaño lo suficientemente grande como para corresponderse con un vaso o una infiltración significativa.




Figura 5: Etiketado de objetos intrarretinales de baja intensidad en retina con DME.

En segunda instancia se buscó segmentar el EPR. Se hizo uso del mismo algoritmo de segmentación, pero en esta ocasión se puso el foco en las regiones de altos valores de intensidad. Entonces, se llevó a cabo un etiquetado de los objetos blancos, con un umbral de binarización de $\max(k_means) - 1$, definiendo un nuevo umbral de tamaño, apropiado para el objeto por aislar: el EPR, ubicado en la parte inferior de la retina. Finalmente, para definir cuál de todos los objetos resultantes del etiquetado seleccionar, se definió una función que calculara la coordenada y promedio de cada objeto, y en base a eso se eligió la etiqueta de menor coordenada y (mayor número de fila). Una vez aislado el EPR (Figura 6), se trazaron tanto la recta como la parábola de mayor ajuste y se calculó el coeficiente de determinación como medida de la deformación retinal.

Se decidió trabajar con la regresión parabólica debido a que los valores de R^2 obtenidos presentaron mayor concordancia con la información conocida de cada retina. Es decir, al calcular el R^2 con la regresión lineal (Figura 10, ubicada en el Anexo), para un EPR sin deformación (pero con patología DME) se obtuvo $R^2 = 0,901$ (lo cual es de esperar e indica alta preservación del EPR), mientras

que para el EPR de una retina sana se obtuvo $R^2 = 0,034$. Esta diferencia sugiere que el parámetro no es lo suficientemente consistente para basar la clasificación en su valor, dado que ambas retinas no presentan deformaciones. En cambio, en el caso de la regresión parabólica (Figura 6), los valores de R^2 obtenidos para las mismas imágenes fueron de 0,939 y 0,844, más acordes a lo esperado.




Figura 6: Cálculo del R^2 en base a la regresión parabólica para una retina con DME (izquierda - $R^2 = 0,939$) y para una retina normal (derecha - $R^2 = 0,844$).

Finalmente, con el fin de profundizar el análisis y comparar resultados, se implementó la técnica de esqueletización sobre el EPR segmentado para luego calcular el coeficiente de determinación (Figura 13, Anexo). Los resultados obtenidos en los casos analizados no variaron significativamente, y se decidió mantener el cálculo del R^2 basado en el esqueleto debido a que enfatizaba las deformaciones del EPR a nivel visual.

4.5. Diagnóstico Final

En base a estos dos parámetros se elaboró el clasificador para llevar a cabo un diagnóstico final. Para ello definimos dos umbrales:

- Umbral R: Representa el umbral del coeficiente de determinación.
- Umbral V: Representa el umbral de la cantidad de vasos y/o infiltraciones.

Si la imagen analizada supera el umbral V y no supera el umbral R, se está ante un caso de CNV. Si la misma supera tanto el umbral V como el R, se clasifica como DME. Por último, si no se supera el umbral V, consiste en una retina normal.

Para definir de manera óptima estos umbrales, se creó una función de *Grid Search*. La misma se alimenta con un mapa de parámetros y evalúa qué combinación de los mismos produce los mejores resultados para el conjunto de entrenamiento mediante el cálculo de los siguientes parámetros: Accuracy, Precision, F1-score, Tasa de FP y Tasa de VP. Se ejecutó esta función con un dataset de entrenamiento consistente en 25 imágenes de cada condición. En base a esos resultados, se determinaron los umbrales y se volvió a ejecutar el clasificador con un nuevo dataset de prueba, consistente en otras 25 imágenes de cada clase, para analizar el rendimiento del algoritmo.

5. Resultados

Para presentar los resultados, se presenta, por un lado, lo obtenido en el entrenamiento y prueba del clasificador como algoritmo, por fuera de la interfaz diseñada, y, por el otro, la funcionalidad de la interfaz creada.

5.1. Rendimiento del clasificador

En una primera instancia se evaluó el rendimiento del clasificador con distintas combinaciones de umbrales. Primero se probaron valores más distanciados entre sí para poder acotar el rango de los

umbrales (Cuadro 2). Después, eligiendo un valor particular para el Umbral V y un rango para el Umbral R, se llevó a cabo una evaluación más detallada (Cuadro 3). Los resultados de ambos *Grid Search* se presentan en el *Anexo*. En base a ellos, se determinó $Umbral_V = 0$ y $Umbral_R = 0,725$, con una *Accuracy* promedio de 0,76 y una *Precisión* promedio de 0,69.

Finalmente, con los umbrales seleccionados se evaluó el clasificador utilizando un nuevo y distinto dataset de prueba, consistente en 25 imágenes de cada categoría. A continuación se presentan los resultados:

	Métrica				
	Accuracy	Precisión	Tasa de VP	Tasa de FP	F1-score
Umbral V = 0 Umbral R = 0,725	0.78	0.78	0.68	0.16	0.66

Cuadro 1: Métricas promedio correspondientes a la combinación de umbrales seleccionada, con el dataset de prueba.

5.2. Funcionalidad de la interfaz

A partir de todo el procesamiento diseñado previamente, se procedió a generar una interfaz gráfica en PyQT5 (Figura 7). Esta misma le permite al usuario seleccionar una imagen y, a partir de ella, realizar un diagnóstico respecto a la condición retinal observada. Entonces, al presionar el botón *Realizar Diagnóstico*, se le da inicio al clasificador de forma tal que, a medida que se realizan los distintos pasos del algoritmo, la interfaz le permite al usuario ver las imágenes resultantes. Estas son la imagen original pre-procesada, la obtenida mediante K-means, la etiquetada para el conteo de vasos e infiltraciones, y la que se utiliza para calcular la regresión parabólica. Por último, una vez que el sistema termina con la clasificación, se imprime el resultado del diagnóstico final con los resultados característicos calculados en la zona inferior derecha de la pantalla.

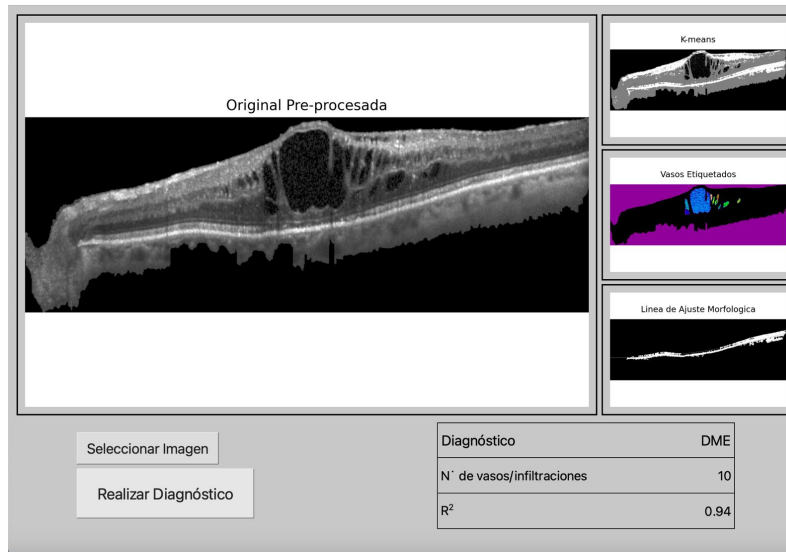


Figura 7: Disposición de la interfaz gráfica generada. Se observa un diagnóstico correspondiente a DME.

6. Conclusión

En este proyecto, se logró implementar una interfaz innovadora denominada "La DesPIBdida", que tiene potencial para asistir al personal médico en el análisis y diagnóstico de patologías retinales a partir de imágenes de OCT. Nuestro enfoque integra diversas técnicas avanzadas de procesamiento de imágenes para proporcionar una herramienta precisa y complementaria en el diagnóstico de DME y CNV respecto a una retina normal.

Utilizando técnicas aprendidas en la cursada, como el filtrado gaussiano y no local para la mejora de imágenes, segmentación mediante k-means, etiquetado, bounding boxes y esqueletización, y parametrización a través de regresiones lineales y parabólicas, se logró obtener un análisis detallado del estado retinal del paciente. La clasificación se basa en la comparación de dos parámetros clave con los umbrales óptimos: la cantidad de vasos o infiltraciones intrarretinales detectadas y el R^2 de la parábola de mejor ajuste al EPR.

Para optimizar el rendimiento del clasificador, se aplicaron técnicas de exploración profunda como la grid search, probando un total de 30 combinaciones diferentes de valores de umbrales. Esta metodología nos permitió definir los umbrales que ofrecen el mejor rendimiento en el clasificador. Así, con el conjunto de prueba, se alcanzó un accuracy promedio de 0.78, una precisión promedio de 0.78, una tasa de verdaderos positivos (VP) promedio de 0.68, una tasa de falsos positivos (FP) promedio de 0.16 y un F1-score promedio de 0.66. Estos resultados reflejan una clasificación robusta y efectiva, proporcionando al personal médico una herramienta confiable para el diagnóstico de patologías retinales.

Sin embargo, reconocemos la posibilidad de mejoras y expansiones en nuestro enfoque. En el futuro, consideraremos la implementación de modelos de machine learning que utilicen datos recopilados para predecir de manera más precisa la presencia de patologías retinales, lo cual podría ofrecer un enfoque más avanzado y abarcativo en el diagnóstico.

7. Referencias

- [1] Zhang, Q., Chen, C. L., Chu, Z., Zheng, F., Miller, A., Roisman, L., De Oliveira Dias, J. R., Yehoshua, Z., Schaal, K. B., Feuer, W., Gregori, G., Kubach, S., An, L., Stetson, P. F., Durbin, M. K., Rosenfeld, P. J., & Wang, R. K. (2017). Automated Quantitation of Choroidal Neovascularization: A Comparison Study Between Spectral-Domain and Swept-Source OCT Angiograms. *Investigative Ophthalmology & Visual Science*, 58(3), 1506.
<https://doi.org/10.1167/iovs.16-20977>
- [2] Casas, D. D. R. (2019, August 13). Anatomía de la Retina con OCT. *Doctor Diego Ruiz Casas*. <https://www.doctordiegoruizcasas.com/anatomia-globo-ocular/oct-retina>
- [3] Ophthalmology Retina. (n.d.).
<https://www.opthalmologyretina.org/article/S2468-6530%2822%2900001-X/fulltext>
- [4] Kermany, D. S., Goldbaum, M., Cai, W., Valentim, C. C., Liang, H., Baxter, S. L., McKeown, A., Yang, G., Wu, X., Yan, F., Dong, J., Prasadha, M. K., Pei, J., Ting, M. Y., Zhu, J., Li, C., Hewett, S., Dong, J., Ziyar, I., & Zhang, K. (2018). Identifying Medical Diagnoses and Treatable Diseases by Image-Based Deep Learning. *Cell*, 172(5), 1122-1131.e9.
<https://doi.org/10.1016/j.cell.2018.02.010>
- [5] Saeidian, J., Mahmoudi, T., Riazi-Esfahani, H., Montazeriani, Z., Khodabande, A., Zarei, M., Ebrahimiadib, N., Jafari, B., Aghaei, A. A., Azimi, H., Pour, E. K. (2023, February 2). Automated assessment of the smoothness of retinal layers in optical coherence tomography images using a machine learning algorithm - BMC Medical Imaging. BioMed Central.
<https://bmcmedimaging.biomedcentral.com/articles/10.1186/s12880-023-00976-w>
- [6] Paultimothymooney. (2018, March 27). Detect retina damage from OCT images. Kaggle.
<https://www.kaggle.com/code/paultimothymooney/detect-retina-damage-from-oct-images/input>

8. Anexo

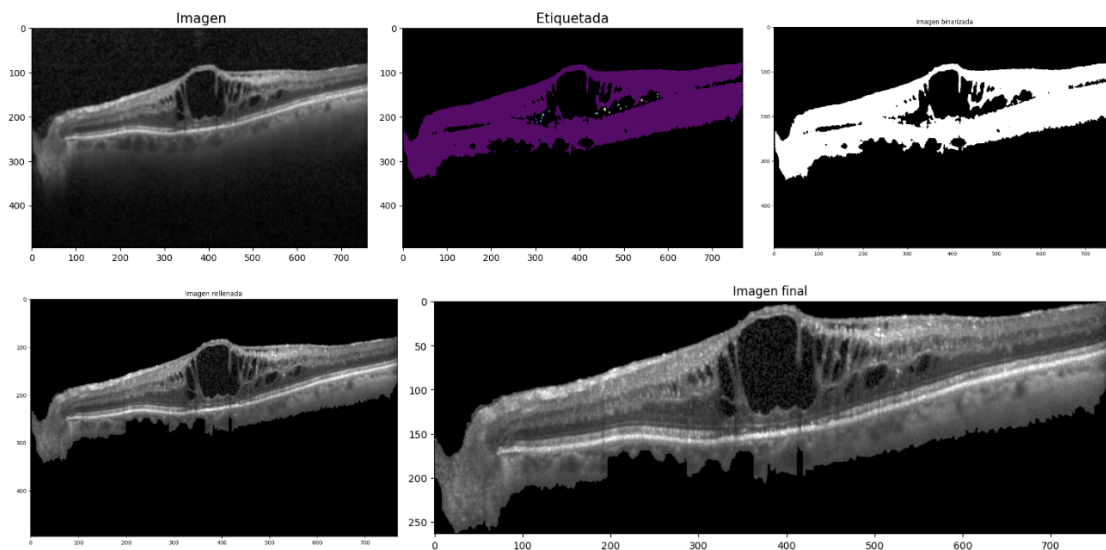


Figura 8: Proceso de pre-procesamiento y mejoramiento de la imagen. De izquierda a derecha y de arriba hacia abajo: Imagen original, etiquetado para el aislamiento de la retina, binarización temporaria para el perfeccionamiento del aislamiento, imagen con fondo limpio (retina aislada), e imagen final.

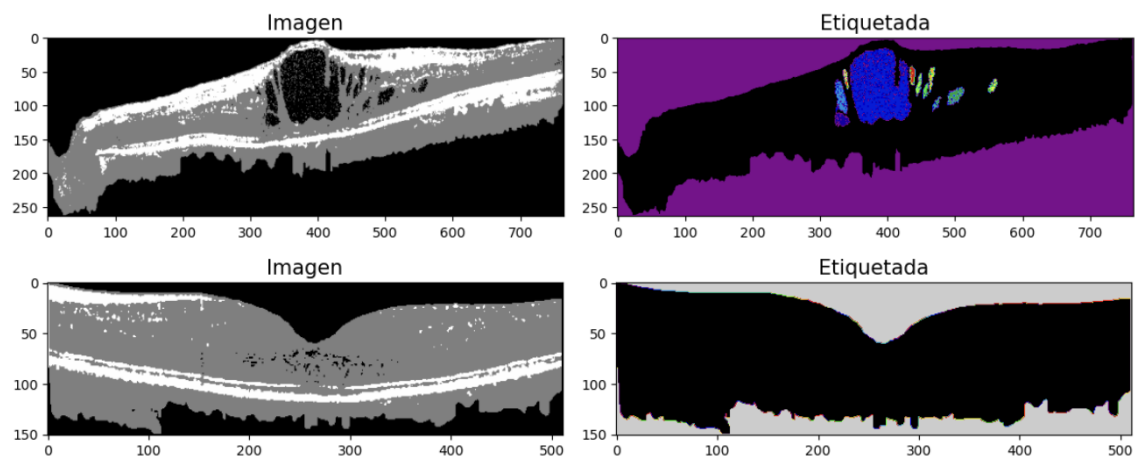


Figura 9: Resultado de la segmentación con K-Medias y posterior etiquetado de vasos e infiltraciones. De arriba hacia abajo, se observa: Caso de retina con DME, Caso de retina normal.




Figura 10: Cálculo del R^2 en base a la regresión lineal para una retina con DME (izquierda - $R^2 = 0,901$) y para una retina normal (derecha - $R^2 = 0,034$). De arriba hacia abajo: objetos pertenecientes al cluster de centroide de máximo valor en el K-means, etiquetado de los mismos, aislamiento del EPR, y regresión lineal sobre el EPR.




Figura 11: Cálculo del R^2 en base a la regresión parabólica sobre la imagen esqueletizada, para una retina con DME (izquierda) y para una retina normal (derecha).




Figura 12: Disposición de la interfaz gráfica generada. Se observa un diagnóstico correspondiente a una retina normal.

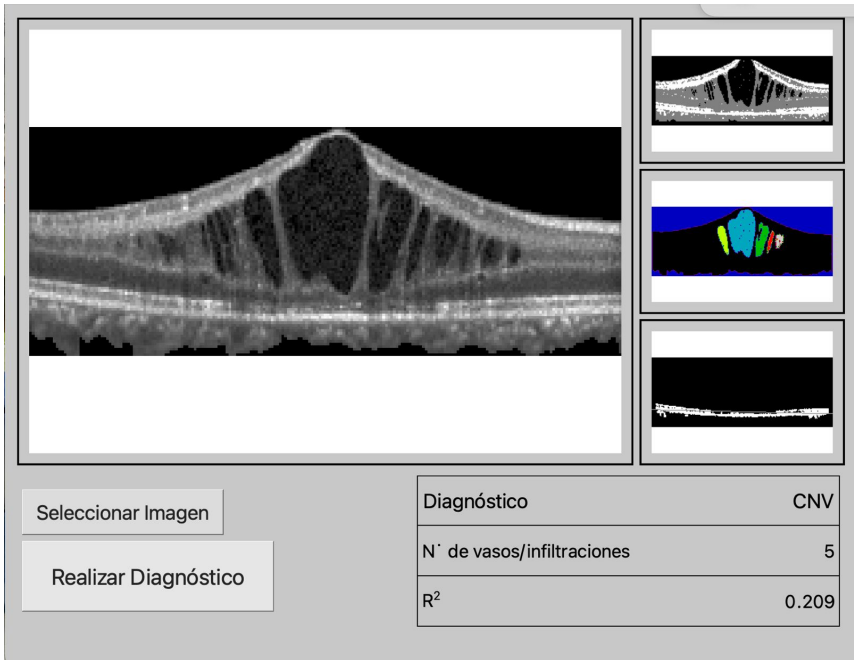


Figura 13: Disposición de la interfaz gráfica generada. Se observa un diagnóstico correspondiente a CNV.

	Métrica				
	Accuracy	Precisión	Tasa de VP	Tasa de FP	F1-score
Umbral V = 0 Umbral R = 0,5	0.72	0.63	0.60	0.20	0.56
Umbral V = 0 Umbral R = 0,6	0.73	0.65	0.61	0.20	0.58
Umbral V = 0 Umbral R = 0,7	0.73	0.65	0.61	0.20	0.59
Umbral V = 0 Umbral R = 0,8	0.72	0.64	0.60	0.21	0.57
Umbral V = 0 Umbral R = 0,9	0.69	0.63	0.56	0.24	0.51
Umbral V = 1 Umbral R = 0,5	0.63	0.53	0.48	0.26	0.40
Umbral V = 1 Umbral R = 0,6	0.63	0.53	0.48	0.26	0.40
Umbral V = 1 Umbral R = 0,7	0.63	0.57	0.48	0.27	0.41
Umbral V = 1 Umbral R = 0,8	0.62	0.55	0.47	0.28	0.40
Umbral V = 1 Umbral R = 0,9	0.58	0.47	0.41	0.31	0.32
Umbral V = 3 Umbral R = 0,5	0.55	0.39	0.39	0.31	0.26
Umbral V = 3 Umbral R = 0,6	0.55	0.39	0.39	0.31	0.26
Umbral V = 3 Umbral R = 0,7	0.56	0.79	0.40	0.30	0.29
Umbral V = 3 Umbral R = 0,8	0.56	0.79	0.40	0.30	0.29
Umbral V = 3 Umbral R = 0,9	0.54	0.56	0.37	0.32	0.25

Cuadro 2: Métricas promedio correspondientes a algunas de las combinaciones evaluadas en la exploración general de valores de umbrales, llevada a cabo con el dataset de entrenamiento.

Métrica	Combinación				
	Umbral_V: 0 Umbral_R: 0.6	Umbral_V: 0 Umbral_R: 0.65	Umbral_V: 0 Umbral_R: 0.675	Umbral_V: 0 Umbral_R: 0.7	Umbral_V: 0 Umbral_R: 0.725
Accuracy	0.761	0.752	0.761	0.752	0.761
Precisión	0.690	0.666	0.688	0.667	0.690
Tasa de VP	0.653	0.640	0.653	0.640	0.653
Tasa de FP	0.176	0.184	0.177	0.185	0.177
F1-score	0.625	0.611	0.630	0.616	0.634

Cuadro 3: Promedios de métricas evaluando con umbrales en rangos acotados.